




Ramen: Robust Test-Time Adaptation of Vision-Language Models with Active Sample Selection
논문 리뷰


- ❖ Background knowledge
 - Test-time adaption
 - Zero shot learning
 - CLIP(vision-language model)
- ❖ Robust Test-Time Adaptation of Vision-Language Models
 - introduction
 - active sample Selection
 - embedding-Gradient Cache
 - overall Framework
- ❖ Experiment & conclusion
 - Experiment
 - conclusion

1. Background knowledge

Zero shot learning

Zero shot learning

: 학습 과정에서 한 번도 본 적 없는 새로운 데이터를 사전 지식과 의미론적 설명을 바탕으로 즉시 인식하고 수행




1. Background knowledge

CLIP

CLIP (Contrastive Language-Image Pre-training)

- 이미지와 텍스트를 함께 이해하여 "이미지 검색"이나 "이미지 분류" 등의 작업을 수행



1. Background knowledge

CLIP

텍스트, 이미지 벡터화

- C개의 카테고리를 가진 분류 태스크의 경우
 - 텍스트 인코더는 각 클래스 설명(예: "a photo of a {object}")을 정규화 된 텍스트 임베딩 $T = [t_1, \dots, t_C]^T \in \mathbb{R}^{C \times d}$ 로 변환합니다(d는 차원)
 - 주어진 테스트 이미지 x_i 에 대해, 이미지 인코더는 정규화 된 임베딩 $z_i \in \mathbb{R}^d$ 을 출력

$$T = \begin{bmatrix} t_1^T \\ t_2^T \\ \vdots \\ t_C^T \end{bmatrix} = \begin{bmatrix} t_{11} & t_{12} & \cdots & t_{1d} \\ t_{21} & t_{22} & \cdots & t_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ t_{C1} & t_{C2} & \cdots & t_{Cd} \end{bmatrix} \in \mathbb{R}^{C \times d}.$$

확률 계산 및 예측

- 이미지 벡터 z_i 와 모든 텍스트 벡터들 T 을 내적하여 유사도를 측정($\exp(t)$: 온도 파라미터)

$$p_i = \text{softmax}(\exp(t) \cdot z_i T^T)$$

- 예측 레이블은 가장 높은 확률을 가진 클래스에 대응합니다.

$$\hat{y}_i = \arg \max_y p_{iy} \text{입니다.}$$

1. Background knowledge

CLIP

- 그러나 강력한 CLIP 성능이 이미지 및 도메인 이동을 포함한 분포 이동 하에서 크게 저하함
 - Image Corruptions: 이미지에 노이즈가 끼거나, 흐려지거나(Blur), 비가 내리는 등의 변형이 생기는 경우
 - Domain Shifts: 실제 사진(Photo)으로만 학습했는데 전혀 다른 도메인의 이미지가 들어오는 경우




- 소스 데이터나 타깃 레이블에 접근하지 않고 테스트 타임 동안 모델을 적응시킴(test-time adaption)

1. Background knowledge

Test-time adaption

도메인 적응 방법론(domain adaption)
: 서로 다른 도메인 데이터셋간 일반화 성능을 높이는 방법론




1. Background knowledge

Test-time adaption

도메인 적응 방법론(domain adaption)

: 서로 다른 도메인 데이터셋간 일반화 성능을 높이는 방법론




1. Background knowledge

Test-time adaption

테스트 시점 적응 방법론(test-time adaption)

: source 도메인 도움 없이 테스트 타임 시점의 새로운 target 도메인 데이터를 일반화를 하는 방법론



Introduction

[문제점]

- 기존의 test-time adaption은 test 샘플들이 하나의 일관된 도메인에서 나온다고 가정에 의존합니다.

엔트로피 최소화

- CLIP의 예측 확률 벡터 $p_i = [p_{i1}, \dots, p_{iC}]^T$ 가 주어졌을 때, 샘플 i 에 대한 엔트로피는
$$H(x_i) = -\sum_{c=1}^C p_{ic} \log p_{ic}$$
(현재 샘플에 대한 모델의 불확실성)
- 실제로 대부분의 방법들이 전체 모델 대신 정규화 레이어만 업데이트 한다.


혼합 도메인 이동의 과제

- 실제 시나리오에서 테스트 데이터는 여러 도메인의 혼합물로 구성 될 수 있다. → 혼합 도메인 이동 하에서 TTA의 효과가 크게 감소됨

Introduction

[문제점]

- 기존의 test-time adaption은 test 샘플들이 하나의 일관된 도메인에서 나온다고 가정에 의존합니다.
 - 실제 테스트 데이터가 서로 다른 특성을 가진 여러 도메인의 샘플을 포함하여 서브옵티멀(Suboptimal, 차선)의 적응 결과를 초래합니다.




[해결책]

- 샘플 선택을 통해 강건한 테스트 타임 적응을 가능하게 한다.(ramen 도입)

Active Sample Selection

- Ramen은 현재 샘플과 가장 연관성이 높은 이전에 보았던 테스트 샘플들의 작은 배치인 **맞춤형 지원 세트** S_i 를 능동적으로 구성합니다.
- 선택되는 샘플들의 결정 기준:
 - 도메인 일관성: 이미지 임베딩 간의 거리를 측정하여 유사한 도메인에서 나온 데이터에 적응이 집중되도록 보장.
 - 예측 균형: 왜곡된 모델 예측으로 인한 적응 편향을 완화합니다.



Active Sample Selection

샘플별 맞춤형 모델 가중치(w_i) 생성

테스트 샘플 x_i 하나하나마다 독립적인 서포트 세트 S_i 를 구성하고, 맞춤형 가중치 w_i 를 유도합니다.

$$\hat{y}_i = \text{CLIP}(x_i; w_i), \quad \text{where } w_i = \text{TTA}(w; S_i)$$

w : 사전 학습된(Pre-trained) 원래 CLIP 모델의 가중치

S_i : 현재 샘플 x_i 를 위해 과거 데이터 중에서 엄선했던 맞춤형 학습 데이터셋(서포트 세트)

w_i : S_i 를 이용해 테스트 타임 어댑테이션(TTA)을 거쳐 얻은 x_i 전용 가중치

where w_i : x_i 전용 가중치를 가진 CLIP 모델이 내린 최종 예측값

클래스 분할 메모리(M 를 통한 실제 구현)

두 가지 까다로운 조건(도메인 일관성 + 예측 균형)을 위해, 클래스 분할 메모리(Class-split Memory, M)을 제안

메모리의 구조: 클래스의 총개수 C 만큼 큐(Queue)를 만듭니다($M_1, \dots, M_C$). 각 큐는 제로샷 분류기가 해당 클래스로 예측한 최근 샘플들을 최대 K 개까지 보관합니다.


작동 프로세스:

- 새로운 테스트 샘플 x_i 가 들어오면 이미지 임베딩 z_i 를 추출합니다.
- [도메인 일관성 확보] 모든 클래스 큐(M_1 부터 M_C 까지)를 돌며, z_i 와 가장 유사한 상위 k 개의 샘플을 각각 뽑아냅니다.
- [예측 균형 확보] 모든 클래스에서 똑같이 k 개씩 뽑았기 때문에, 이들을 다 합쳐서 만든 최종 서포트 세트 S_i 는 모든 클래스가 동일한 비율로 존재하는 완벽하게 균형 잡힌 상태가 됩니다.

$$S_i = \bigcup_{c=1}^C S_i^c, \quad \text{where } S_i^c = \text{Top-}k_{j \in M_c}(z_i^\top z_j)$$

Embedding-Gradient Cache

- 과거 테스트 이미지의 임베딩과 샘플 단위의 그래디언트를 모두 저장하여 캐시계산 비용을 절감 할수 있다.
(임베딩-그래디언트 캐시)



Embedding-Gradient Cache

- 표준 TTA에서는 각 테스트 샘플 x_i 는 $C \cdot k$ 번의 역방향 연산을 요구하게 되어 전체 계산 비용이 $C \cdot k$ 배만큼 팽창
- è 공통 TTA 목적 함수의 점별(Point-wise) 특성을 활용(임베딩-그래디언트 캐시)
- 엔트로피 손실의 경우, 배치 S_i 에 대한 손실은 샘플 단위 손실의 가중 평균으로 작성

$$\mathcal{L}(S_i) = \sum_{j \in S_i} \alpha_{ij} H(x_j)$$

➤ α_{ij} : 샘플 j 의 가중치

- 배치에 대한 그래디언트: $\nabla_w H(S_i) = \sum_{j \in S_i} \alpha_{ij} g_j$, where $g_j = \nabla_w H(x_j)$

Embedding-Gradient Cache


임베딩-그라디언트 캐시의 작동 단계

1. 새 이미지 계산: 새 이미지 i 가 들어오면, 개의 임베딩(z_i), 예측 결과($\hat{y}_i$), 그리고 과거 그라디언트(g_i)를 계산합니다.
2. 메모리 저장: 방금 계산한 따끈따끈한 세트를 메모리 방에 집어넣습니다.
3. 유사 샘플 검색: 내 임베딩(z_i)과 과거 임베딩(z_j)들을 비교해서 도메인이 비슷한 과거 샘플(지원 세트 S_i)을 골라냅니다.
4. 초고속 오답 가중 취합: 새로 연산하지 않고, 캐시 메모리에 잠자고 있던 과거 그라디언트(g_j)들을 식 최종 식의 가중치로 쓱쓱 더해서 최종 그라디언트를 만듭니다. 이 값으로 모델을 업데이트합니다.
5. 추론 및 리셋: 업데이트된 모델로 현재 이미지의 진짜 정답을 예측한 뒤, 모델을 다시 깨끗한 원래 상태로 되돌립니다.

$$\longrightarrow \alpha_{ij} = \exp(-H(x_j)) \cdot \exp(-\beta \cdot \|z_i - z_j\|_2)$$

- $\exp(-H(x_j))$: 엔트로피 가중치
- $\exp(-\beta \cdot \|z_i - z_j\|_2)$: 유사도 가중치

Overall Framework



Experiment

실험 설정 및 주요 결과 (RQ1)

- 실험 목적: 혼합 도메인 이동(Mixed-Domain Shifts) 환경에서 Ramen의 강건성 검증
- 실험 세팅 (뒤섞인 데이터 스트리밍):
 - 여러 도메인을 분리하지 않고 완전히 뒤섞어(Fully Interleaved) 실시간 입력 및 평가
 - CIFAR-10-C / CIFAR-100-C / ImageNet-C: 15종의 이미지 손상 혼합 환경
 - DomainNet: 6개 실제 도메인 혼합 환경

주요 성과 (모든 벤치마크 최고 성능 SOTA 달성):

- 기존 최신 TTA 방식들은 도메인이 혼합되면 성능이 붕괴되나, Ramen은 강건함(Robustness) 유지
- 가장 강력한 베이스라인 대비 평균 정확도(Accuracy) 향상치:
 - CIFAR-10-C: + 1.3%
 - CIFAR-100-C: + 3.4%
 - ImageNet-C: + 2.5%
 - DomainNet: + 0.6%

Experiment

메커니즘 검증 및 계산 효율성 (RQ2 & RQ3)

- 활성 샘플 선택의 시각적 검증 (RQ2):
 - 현재 쿼리 이미지와 정확히 일치하는 도메인의 샘플을 평균 40.9% 비율로 정밀하게 검색
 - 완전히 무작위로 선택했을 때의 확률인 6.7%보다 약 6배 이상 높은 수치
 - →임베딩 공간에서 유사한 도메인의 과거 데이터를 완벽히 추출함을 증명
- 초고속 연산 및 효율성 (RQ3):
 - 컴퓨팅 시간 비교 (CIFAR-100-C, 15만 장 기준):
 - 캐시가 없는 Naive 구현: 약 115시간 42분 (실시간 적용 불가)
 - 임베딩-그래디언트 캐시 적용 (Ramen): 단 14분 08초
 - →과거 연산 결과를 재활용하는 캐시 트릭으로 490배의 속도 향상(Speedup) 달성
 - 기존의 가벼운 방식(Tent, 9분대)들과 시간은 대등하면서 정확도는 압도적

최종 결론 및 핵심 기여점:

- 혼합 도메인 이동 하에서 강건한 테스트 타임 적응을 위한 프레임워크인 Ramen을 제시
- 안정적이고 편향 없는 적응을 달성 및 이론적 및 경험적 결과는 그것의 강건성과 효율성을 입증함
- 효율적인 임베딩-그래디언트 캐시를 통해 추가적인 계산 없이 빠른 업데이트가 가능함.



가천대학교
감사합니다