



Ramen: Robust Test-Time Adaptation of Vision-Language Models with Active Sample Selection

논문 리뷰


contents

❖ Background knowledge



➤ Test-time adaption

❖ Robust Test-Time Adaptation of Vision-Language Models



➤ introduction

➤ active sample Selection

➤ embedding-Gradient Cache

➤ overall Framework

❖ Experiment & conclusion

➤ Experiment


➤ conclusion

1. Background knowledge

CLIP

Contrastive Learning

- 레이블링 없이 학습하는 Self-supervised Learning 방법론 중에 한가지 방법
- 특정 입력을 Embedding Network를 통해 임베딩 공간으로 이동
- 같은 class라면 임베딩 값의 거리를 최소화(d^+)하고, 다른 class라면 임베딩 값의 거리를 최대화 (d^-)




1 Background knowledge

CLIP

CLIP (Contrastive Language-Image Pre-training)

- 이미지와 텍스트를 함께 이해하여 "이미지 검색"이나 "이미지 분류" 등의 작업을 수행



1. Background knowledge

CLIP

텍스트, 이미지 벡터화

- C개의 카테고리를 가진 분류 태스크의 경우
 - 텍스트 인코더는 각 클래스 설명(예: "a photo of a {object}")을 정규화 된 텍스트 임베딩 $T = [t_1, \dots, t_C]^T \in \mathbb{R}^{C \times d}$ 로 변환합니다 (d는 차원)
 - 주어진 테스트 이미지 x_i 에 대해, 이미지 인코더는 정규화 된 임베딩 $z_i \in \mathbb{R}^d$ 을 출력

$$T = \begin{bmatrix} t_1^T \\ t_2^T \\ \vdots \\ t_C^T \end{bmatrix} = \begin{bmatrix} t_{11} & t_{12} & \cdots & t_{1d} \\ t_{21} & t_{22} & \cdots & t_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ t_{C1} & t_{C2} & \cdots & t_{Cd} \end{bmatrix} \in \mathbb{R}^{C \times d}.$$

확률 계산 및 예측

- 이미지 벡터 z_i 와 모든 텍스트 벡터들 T 을 내적하여 유사도를 측정 ($\exp(t)$: 온도 파라미터)

$$p_i = \text{softmax}(\exp(t) \cdot z_i T^T)$$

- 예측 레이블은 가장 높은 확률을 가진 클래스에 대응


$$\hat{y}_i = \arg \max_y p_{iy} \text{입니다.}$$

1 Background knowledge

CLIP

- 그러나 강력한 CLIP 성능이 이미지 및 도메인 이동을 포함한 분포 이동 하에서 크게 저하함

- Image Corruptions: 이미지에 노이즈가 끼거나, 흐려지거나(Blur), 비가 내리는 등의 변형이 생기는 경우
- Domain Shifts: 실제 사진(Photo)으로만 학습했는데 전혀 다른 도메인의 이미지가 들어오는 경우




- 소스 데이터나 타깃 레이블에 접근하지 않고 테스트 타임 동안 모델을 적응시킴(test-time adaption)

1. Background knowledge

Test-time adaption

도메인 적응 방법론(domain adaption)

: 서로 다른 도메인 데이터셋간 일반화 성능을 높이는 방법론




1. Background knowledge

Test-time adaption

도메인 적응 방법론(domain adaption)

: 서로 다른 도메인 데이터셋간 일반화 성능을 높이는 방법론




1. Background knowledge

Test-time adaption

테스트 시점 적응 방법론(test-time adaption)

: source 도메인 도움 없이 테스트 타임 시점의 새로운 target 도메인 데이터를 일반화를 하는 방법론




2. Robust Test-Time Adaptation of Vision-Language Models

Introduction

[문제점]

- 기존의 test-time adaption은 test 샘플들이 하나의 일관된 도메인에서 나온다고 가정에 의존합니다.
 - 실제 테스트 데이터가 서로 다른 특성을 가진 여러 도메인의 샘플을 포함하여 서브옵티멀(Suboptimal, 차선)의 적응 결과를 초래합니다.



[해결책]

- 샘플 선택을 통해 강건한 테스트 타임 적응을 가능하게 한다.(ramen 도입)

2. Robust Test-Time Adaptation of Vision-Language Models

Introduction



[문제점]

- 기존의 test-time adaption은 test 샘플들이 하나의 일관된 도메인에서 나온다고 가정에 의존.

엔트로피 최소화

- CLIP의 예측 확률 벡터 $p_i = [p_{i1}, \dots, p_{ic}]^T$ 가 주어졌을 때, 샘플 i 에 대한 엔트로피는
$$H(x_i) = -\sum_{c=1}^C p_{ic} \log p_{ic}$$
(현재 샘플에 대한 모델의 불확실성)
- 이후 실제로 모델 전체를 업데이트하지 않고 대부분의 방법들이 전체 모델 대신 정규화 레이어만 업데이트 한다.



혼합 도메인 이동의 과제

- 실제 시나리오에서 테스트 데이터는 여러 도메인의 혼합물로 구성될 수 있다.-> 혼합 도메인 이동 하에서 TTA의 효과가 크게 감소됨

2. Robust Test-Time Adaptation of Vision-Language Models

Active Sample Selection

- Ramen은 현재 샘플과 가장 연관성이 높은 이전에 보았던 테스트 샘플들의 작은 배치인 **맞춤형 지원 세트** S_i 를 능동적으로 구성합니다.
- 선택되는 샘플들의 결정 기준:
 - 도메인 일관성: 이미지 임베딩 간의 거리를 측정하여 유사한 도메인에서 나온 데이터에 적응이 집중되도록 보장.
 - 예측 균형: 왜곡된 모델 예측으로 인한 적응 편향을 완화.



2. Robust Test-Time Adaptation of Vision-Language Models

Active Sample Selection

샘플별 맞춤형 모델 가중치(w_i) 생성

테스트 샘플 x_i 하나하나마다 독립적인 서포트 세트 S_i 를 구성하고, 맞춤형 가중치 w_i 를 유도합니다.

$$\hat{y}_i = \text{CLIP}(x_i; w_i), \quad \text{where } w_i = \text{TTA}(w; S_i)$$

w : 사전 학습된(Pre-trained) 원래 CLIP 모델의 가중치
 S_i 현재 샘플 x_i 를 위해 과거 데이터 중에서 엄선했던 맞춤형 학습 데이터 셋(서포트 세트)

w_i : S_i 를 이용해 테스트 타임 어댑테이션(TTA)을 거쳐 얻은 x_i 전용 가중치

$\hat{y}_i$: x_i 전용 가중치를 가진 CLIP 모델이 내린 최종 예측값

클래스 분할 메모리(M 를 통한 실제 구현)

두 가지 까다로운 조건(도메인 일관성 + 예측 균형)을 위해, 클래스 분할 메모리(Class-split Memory, M)을 제안

메모리의 구조: 클래스의 총개수 C 만큼 큐(Queue)를 만듭니다($M_1, \dots, M_C$). 각 큐는 제로샷 분류기가 해당 클래스로 예측한 최근 샘플들을 최대 K 개까지 보관함.

작동 프로세스:

- 새로운 테스트 샘플 x_i 가 들어오면 이미지 임베딩 z_i 를 추출.
- 모든 클래스 큐(M_1 부터 M_C 까지)를 돌며 z_i 와 가장 유사한 상위 k 개의 샘플을 각각 뽑음.
- 이들을 다 합쳐서 만든 최종 서포트 세트 S_i 는 모든 클래스가 동일한 비율로 존재하는 완벽하게 균형 잡힌 상태가 된다.


$$S_i = \bigcup_{c=1}^C S_i^c, \quad \text{where } S_i^c = \text{Top-}k_{j \in M_c}(z_i^\top z_j)$$

2. Robust Test-Time Adaptation of Vision-Language Models

Embedding-Gradient Cache

임베딩-그래디언트 캐시

- 과거 테스트 이미지의 임베딩과 샘플 단위의 그래디언트를 모두 저장함
- 저장된 임베딩은 샘플 검색에 사용되고, 해당하는 그래디언트들은 모델 업데이트를 위해 취합되므로 추가적인 순방향 또는 역방향 연산의 필요성을 배제



2. Robust Test-Time Adaptation of Vision-Language Models

Embedding-Gradient Cache

[문제점]

- 표준 TTA: 각 테스트 샘플 x_i 는 $C \cdot k$ 번의 역방향 연산을 요구하게 되어 전체 계산 비용이 $C \cdot k$ 배만큼 팽창

➔ 공통 TTA 목적 함수의 샘플 단위(Point-wise) 특성을 활용(임베딩-그래디언트 캐시)

- 엔트로피 손실의 경우, 배치 S_i 에 대한 손실은 샘플 단위 손실의 가중 평균으로 작성

$$\mathcal{L}(S_i) = \sum_{j \in S_i} \alpha_{ij} H(x_j)$$

- 배치에 대한 그래디언트: $\nabla_w \mathcal{L}(S_i) = \sum_{j \in S_i} \alpha_{ij} g_j$ where $g_j = \nabla_w H(x_j)$
-> 샘플 단위의 그래디언트 $g_j = \nabla_w H(x_j)$ 를 메모리에 캐시함.

➤ α_{ij} : 샘플 j 의 가중치

2. Robust Test-Time Adaptation of Vision-Language Models

Embedding-Gradient Cache

임베딩-그래디언트 캐시의 작동 단계

1. 이미지 임베딩 z_i , 의사 레이블(Pseudo-label) $\hat{y}_i$, 그리고 샘플 단위 그래디언트 g_i 를 계산
2. 새 엔트리(z_i, g_i)로 메모리 $M_{\hat{y}_i}$ 를 업데이트
3. 내 임베딩(z_i)과 과거 임베딩(z_j)들을 비교해서 도메인이 비슷한 과거 샘플(지원 세트 S_i)을 골라낸다.
4. 새로 연산하지 않고, 캐시 메모리에 잠자고 있던 과거 그래디언트(g_j)들을 식 최종 식의 가중치로 더해서 최종 그래디언트를 만든다. 이 값으로 모델을 업데이트
5. 업데이트된 모델로 현재 이미지의 진짜 정답을 예측한 뒤, 모델을 다시 깨끗한 원래 상태로 되돌린다.

$$\longrightarrow \alpha_{ij} = \exp(-H(x_j)) \cdot \exp(-\beta \cdot \|z_i - z_j\|_2)$$

- $\exp(-H(x_j))$: 엔트로피 가중치
- $\exp(-\beta \cdot \|z_i - z_j\|_2)$: 유사도 가중치

Overall Framework




Figure 1. Overview of *Ramen*. For each test sample, (1) compute its image embedding, pseudo-label, and sample-level gradient; (2) update the class-specific memory with these entries; (3) retrieve a support set from the memory; (4) aggregate the cached gradients for model update; and (5) perform inference and reset the model parameters.

Experiment

실험 설정 및 주요 결과 (RQ1)

- 실험 세팅:
 - 여러 도메인을 분리하지 않고 완전히 뒤섞어(Fully Interleaved) 실시간 입력 및 평가
 - CIFAR-10-C / CIFAR-100-C / ImageNet-C: 15종의 이미지 손상 혼합 환경
 - DomainNet: 6개 실제 도메인 혼합 환경

주요 성과 (모든 벤치마크 최고 성능 SOTA 달성):

- 기존 최신 TTA 방식들은 도메인이 혼합되면 성능이 붕괴되나, Ramen은 강건함(Robustness) 유지
- 가장 강력한 베이스라인 대비 평균 정확도(Accuracy) 향상치:
 - CIFAR-10-C: +1.3%
 - CIFAR-100-C: +3.4%
 - ImageNet-C: +2.5%
 - DomainNet: +0.6%

Experiment

ViT-B/32 on CIFAR-10-C																	
Method	Venue	Noise			Blur				Weather				Digital				Avg.
		Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	
CLIP [33]	ICML'21	35.5	40.0	43.2	70.0	41.4	64.5	70.2	70.8	72.3	66.7	81.4	64.5	59.6	48.2	56.7	59.0
Ensemble	-	38.6	42.6	42.7	72.4	43.9	66.6	71.6	73.8	75.7	69.0	83.6	67.0	61.9	51.8	58.6	61.3
Tent [39]	ICLR'21	39.5	43.1	46.4	77.8	56.6	72.7	77.9	79.7	79.9	74.0	86.9	75.5	69.7	60.3	63.9	66.9
NOTE [12]	NeurIPS'22	44.9	48.3	48.9	77.1	57.0	74.0	77.6	78.0	79.2	73.0	86.5	73.5	68.7	57.9	62.2	67.1
SAR [28]	ICLR'23	48.8	51.8	51.0	77.5	60.5	74.8	79.2	79.6	80.7	76.6	87.4	77.0	71.0	57.5	62.8	69.1
RoTTA [45]	CVPR'23	53.1	56.4	51.3	78.1	61.0	75.2	79.0	79.0	80.1	80.0	85.6	82.9	73.7	65.3	69.9	71.4
TDA [21]	CVPR'24	39.8	42.8	43.4	73.5	45.4	67.6	73.2	74.3	76.4	69.8	84.0	66.6	62.5	52.1	57.7	61.9
DMN-ZS [51]	CVPR'24	38.4	41.7	42.4	73.1	44.6	67.2	72.8	74.6	76.3	69.5	84.0	66.5	62.3	52.4	58.3	61.6
WATT-S [30]	NeurIPS'24	47.4	49.7	49.5	77.0	54.3	72.9	77.3	77.8	79.5	74.8	86.4	74.1	67.8	57.2	62.9	67.2
CLIPArTT [15]	WACV'25	37.2	41.5	44.8	70.5	48.9	65.5	70.7	72.9	75.3	67.4	82.8	66.9	61.9	58.5	59.5	61.6
Mint [3]	NeurIPS'25	47.9	50.9	50.3	74.1	51.3	75.8	76.9	76.4	77.0	73.8	85.8	73.8	65.8	47.3	56.4	65.6
Ramen	-	61.0	63.3	56.0	77.2	64.1	77.2	78.9	80.9	80.3	78.0	88.1	79.8	72.0	65.5	67.5	72.7

ViT-B/16 on CIFAR-100-C																	
Method	Venue	Noise			Blur				Weather				Digital				Avg.
		Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	
CLIP [33]	ICML'21	19.7	21.4	25.3	42.5	20.2	43.1	48.0	48.4	49.7	41.7	57.0	34.5	29.2	23.9	32.4	35.8
Ensemble	-	22.9	24.4	29.6	43.6	20.1	43.7	48.7	48.9	50.4	41.8	58.1	35.3	29.2	26.3	33.6	37.1
Tent [39]	ICLR'21	24.9	26.7	34.4	49.7	23.9	47.5	53.9	52.9	51.4	45.3	62.9	43.6	32.0	31.7	37.1	41.2
NOTE [12]	NeurIPS'22	25.7	27.3	35.4	49.9	23.9	47.6	54.2	52.7	51.8	45.9	63.7	44.0	32.4	30.2	36.0	41.4
SAR [28]	ICLR'23	28.4	30.5	38.5	50.4	24.6	49.2	55.1	54.1	53.4	47.2	64.0	45.0	33.6	29.7	37.4	42.7
RoTTA [45]	CVPR'23	22.9	24.5	32.4	47.9	25.4	46.5	50.1	50.5	50.7	50.8	58.3	53.1	37.7	29.9	36.2	41.1
TDA [21]	CVPR'24	23.4	25.2	30.3	44.1	20.3	43.8	49.1	49.3	51.3	42.2	58.7	36.1	29.3	26.4	33.6	37.5
DMN-ZS [51]	CVPR'24	22.9	24.4	29.6	44.3	20.2	44.1	49.4	49.7	51.1	42.2	58.8	35.5	29.4	26.2	34.0	37.5
WATT-S [30]	NeurIPS'24	26.4	28.4	35.6	50.2	24.2	48.5	54.4	54.2	54.0	47.7	63.5	43.3	34.0	31.4	37.7	42.2
CLIPArTT [15]	WACV'25	21.1	22.8	29.4	46.3	24.5	45.0	51.1	51.5	51.8	44.0	61.1	39.0	33.2	28.3	36.7	39.0
Mint [3]	NeurIPS'25	22.3	24.5	33.0	49.2	22.4	47.8	54.2	52.4	51.6	47.7	63.7	42.2	31.8	24.0	34.3	40.1
Ramen	-	30.3	32.9	42.8	52.5	29.1	52.2	55.5	55.4	55.1	52.6	65.9	51.0	36.8	40.4	39.6	46.1


Experiment

ViT-L/14 on ImageNet-C																	
Method	Venue	Noise			Blur				Weather				Digital				Avg.
		Gauss.	Shot	Impul.	Defoc.	Glass	Motion	Zoom	Snow	Frost	Fog	Brit.	Contr.	Elastic	Pixel	JPEG	
CLIP [33]	ICML'21	27.4	29.4	28.7	34.6	25.3	41.0	36.7	49.8	44.1	49.7	65.4	35.1	30.3	53.5	42.2	39.6
Ensemble	-	29.1	30.4	30.1	37.5	27.3	44.2	39.2	52.4	46.4	52.6	67.8	34.4	32.4	56.2	44.2	41.6
Tent [39]	ICLR'21	36.3	38.0	38.5	<u>40.3</u>	37.4	<u>47.7</u>	<u>43.5</u>	54.2	49.5	56.4	67.8	45.4	40.6	57.6	46.6	<u>46.7</u>
NOTE [12]	NeurIPS'22	36.3	38.0	38.6	40.0	37.3	47.6	<u>43.5</u>	<u>54.4</u>	49.7	56.4	67.8	44.5	40.8	57.5	46.2	46.6
SAR [28]	ICLR'23	36.3	38.3	38.5	39.2	<u>38.5</u>	46.8	43.4	53.9	<u>50.4</u>	<u>56.6</u>	66.8	<u>45.5</u>	<u>41.8</u>	56.2	46.6	46.6
RoTTA [45]	CVPR'23	<u>37.4</u>	<u>38.7</u>	<u>39.6</u>	36.9	34.5	44.0	39.3	53.5	48.6	54.2	67.2	43.0	39.7	56.3	<u>48.4</u>	45.4
TDA [21]	CVPR'24	29.6	31.0	31.5	38.1	28.9	44.6	40.0	53.4	47.5	53.3	<u>68.5</u>	39.1	33.4	57.1	45.1	42.7
DMN-ZS [51]	CVPR'24	29.2	30.5	30.2	37.6	27.6	44.4	39.2	52.5	46.6	52.7	67.9	33.8	32.5	56.5	44.5	41.7
WATT-S [30]	NeurIPS'24	31.8	33.1	33.6	39.2	30.7	45.7	41.3	53.5	47.3	53.7	67.9	40.1	34.7	57.3	45.6	43.7
CLIPArTT [15]	WACV'25	28.2	30.2	29.8	35.0	26.5	41.4	37.3	50.3	43.7	49.7	65.0	38.5	31.0	53.5	42.3	40.2
Mint [3]	NeurIPS'25	33.8	35.2	35.8	39.3	33.3	46.2	41.5	53.6	47.4	53.3	67.7	36.3	38.2	<u>58.1</u>	47.4	44.5
Ramen	-	37.5	38.8	41.1	42.2	39.6	49.9	46.2	57.3	51.6	59.4	68.7	46.4	45.2	59.4	54.7	49.2

Method	Venue	ViT-B/32 on DomainNet						
		clip	info	paint	quick	real	sketch	Avg.
CLIP [33]	ICML'21	67.6	41.5	62.7	12.8	81.0	58.1	54.0
Ensemble	-	68.9	44.2	64.7	13.3	82.3	60.3	55.6
Tent [39]	ICLR'21	69.1	44.3	64.9	13.0	82.3	60.3	55.7
NOTE [12]	NeurIPS'22	<u>69.6</u>	<u>45.1</u>	65.0	16.4	82.1	<u>60.8</u>	<u>56.5</u>
SAR [28]	ICLR'23	69.4	44.7	65.2	14.5	<u>82.5</u>	<u>60.8</u>	56.2
RoTTA [45]	CVPR'23	69.4	44.8	<u>65.3</u>	14.3	82.4	<u>60.8</u>	56.2
TDA [21]	CVPR'24	68.9	44.7	65.1	14.6	82.3	60.5	56.0
DMN-ZS [51]	CVPR'24	68.9	44.6	64.8	12.7	82.6	60.2	55.6
WATT-S [30]	NeurIPS'24	68.3	42.8	63.5	<u>17.0</u>	81.4	59.9	55.5
CLIPArTT [15]	WACV'25	67.2	41.9	62.9	12.6	80.8	57.8	53.9
Mint [3]	NeurIPS'25	69.3	44.4	65.0	15.0	82.3	60.5	56.1
Ramen	-	70.1	45.2	65.8	17.6	82.4	61.5	57.1

Experiment

- 활성 샘플 선택의 시각적 검증 (RQ2):
 - 현재 쿼리 이미지와 정확히 일치하는 도메인의 샘플을 평균 40.9% 비율로 정밀하게 검색
 - 완전히 무작위로 선택했을 때의 확률인 6.7%보다 약 6배 이상 높은 수치
 - → 임베딩 공간에서 유사한 도메인의 과거 데이터를 완벽히 추출함을 증명



Experiment

- 초고속 연산 및 효율성 (RQ3):
 - 컴퓨팅 시간 비교 (CIFAR-100-C, 15만 장 기준):
 - 캐시가 없는 Naive 구현: 약 115시간 42분 (실시간 적용 불가)
 - 임베딩-그래디언트 캐시 적용 (Ramen): 단 14분 08초
 - 과거 연산 결과를 재활용하는 캐시 트릭으로 490배의 속도 향상(Speedup) 달성
 - 기존의 가벼운 방식(Tent, 9분대)들과 시간은 대등하면서 정확도는 압도적

Table 3. Comparison of testing time on CIFAR-100-C.

Method	Testing Time	Acc. (%)	Gain (%)
CLIP	5m27s	35.8	-
Tent	9m27s	41.2	+5.4
NOTE	11m42s	41.4	+5.6
SAR	15m50s	42.7	+6.9
RoTTA	19m29s	41.1	+5.3
TDA	7m59s	37.5	+1.7
DMN-ZS	7m36s	37.5	+1.7
WATT-S	18h54m50s	42.2	+6.4
CLIPArTT	3h05m36s	39.0	+3.2
Mint	13m36s	40.1	+4.3
<i>Ramen</i>	14m08s	46.1	+10.3
(w/o embed-grad cache)	115h42m18s	46.1	+10.3

conclusion

최종 결론 및 핵심 기여점:

- 혼합 도메인 이동 하에서 강건한 테스트 타임 적응을 위한 프레임워크인 Ramen을 제시
- 안정적이고 편향 없는 적응을 달성 및 이론적 및 경험적 결과는 그것의 강건성과 효율성을 입증함
- 효율적인 임베딩-그래디언트 캐시를 통해 추가적인 계산 없이 빠른 업데이트가 가능함.



가천대학교
감사합니다